ANÁLISIS DRUG

PROYECTO 2 ANÁLISIS DATOS I

PELAYO OCAÑA CAMACHO

ÍNDICE:

- Introducción del contexto del estudio, presentación de la base datos y explicación de las variables.
- Exploración y Preprocesamiento de los Datos.
- Análisis exploratorio de los datos.
- Identificación y corrección de variables faltantes o inconsistencias.
- Visualización d distribuciones.
- Modificación de variables.
- Normalización de variables.
- Implementación de Modelos.
- Implementación de KNN.
- Implementación de KNN con diferentes valores.
- Determinación de K óptimo.
- Evaluación de KNN.
- Implementación de Árboles de decisión.
- Ajuste de hiper-parámetros requeridos y criterios de división.
- Uso de Validación cruzada para hiper-parámetros.
- Evaluación de Árbol de Decisión.
- Comparación de los modelos.

Introducción del contexto del estudio, presentación de la base datos y explicación de las variables.

Somos un servicio de asistencia médica privada y se nos han proporcionado una serie de datos en función a los diferentes baremos y variables en las muestras de sangre de nuestros clientes. Dicho estudio se lleva a cabo con el objetivo de en caso de urgencia saber qué tipo de droga o medicamento podría aplicárseles.

La selección del medicamento a suministrar se hará en base a los diferentes valores que tengamos, como son el Sodio (Na), Potasio(K), Sexo del paciente (Sex), Presión Sanguínea (BP, blood pressure) y colesterol (Cholesterol).

A continuación, les explicaremos brevemente las diferentes variables y los valores que pueden tomar.

- **Sodio: nivel de sodio en sangre, variable numérica, valores normales son entre 135-145 mEq/L**
- **Potasio: nivel de potasio en sangre, 3.6-5.2 mmol/L**
- **Sexo del paciente: masculino o femenino**
- **Presión Sanguínea: la hemos categorizado en diferentes clases, como son baja, media y alta**
- **Colesterol: clasificado en dos clases, alto y no alto.**

Una vez, ya tenemos conocimiento de las diferentes variables a considerar en este estudio, les presentamos una exploración inicial del conjunto de datos, y por ende de las muestras de nuestros pacientes.

Exploración y Preprocesamiento de los Datos.

Comenzamos la exploración y el preprocesamiento de datos, con la impresión del dataset. Una vez lo hemos impreso podemos observar las principales columnas que alberga. Para obtener información principal mas relevante, empleamos la función info(), la cual nos permite conocer la naturaleza de las diferentes variables a estudiar. Donde podemos apreciar que todas son de tipo "object", salvo la variable Age, la cual es de tipo entero. Posteriormente se modificarán la naturaleza de estas variables.

Empleamos la función describe(), la cual nos proporciona información de tipo estadístico acerca de las variables en caso de incluir todas(include='all'). Extraemos que la edad media de los pacientes está en torno a los 44 años, el valor máximo de Sodio es de 0,79 y el de Potasio de 0,31, el sexo que más se repite es el masculino, el cual abunda con una cifra de 104 personas.

Hemos aplicado la misma función, pero únicamente a las variables numéricas, como son K, Na y Age.

- El rango de edad se sitúa entre los 15 y 74 años.
- La media del Sodio en sangre es de 0,7.
- La media de Potasio en sangre es de 0,05.

La función value_counts() ha sido empleada, con el objetivo de esquematizar de manera superficial la información.

Identificación de valores faltantes o inconsistencias

Como parte de esta tarea inicial de preprocesamiento de los datos, hemos realizado una búsqueda con el objetivo de encontrar valores faltantes o inconsistencias entre los mismos.

- Para ello hemos empleado dos funciones:
- Isnull(),
- Isnull().sum

Lo cual nos ha permitido descartar posibles ausencias o falta de coherencia en el conjunto de datos, evaluando columna por columna cada una de las variables, al no ser muy numerosas lo he podido hacer de forma manual.

Identificación de relaciones entre variables y distribuciones

1. **Histograma sobre la variable Age:**
   Lo cual nos ha permitido ver como se distribuye la edad de los diferentes pacientes. Detectamos una predominancia de aquellos cuya edad se sitúa en el rango de 45-50 años.

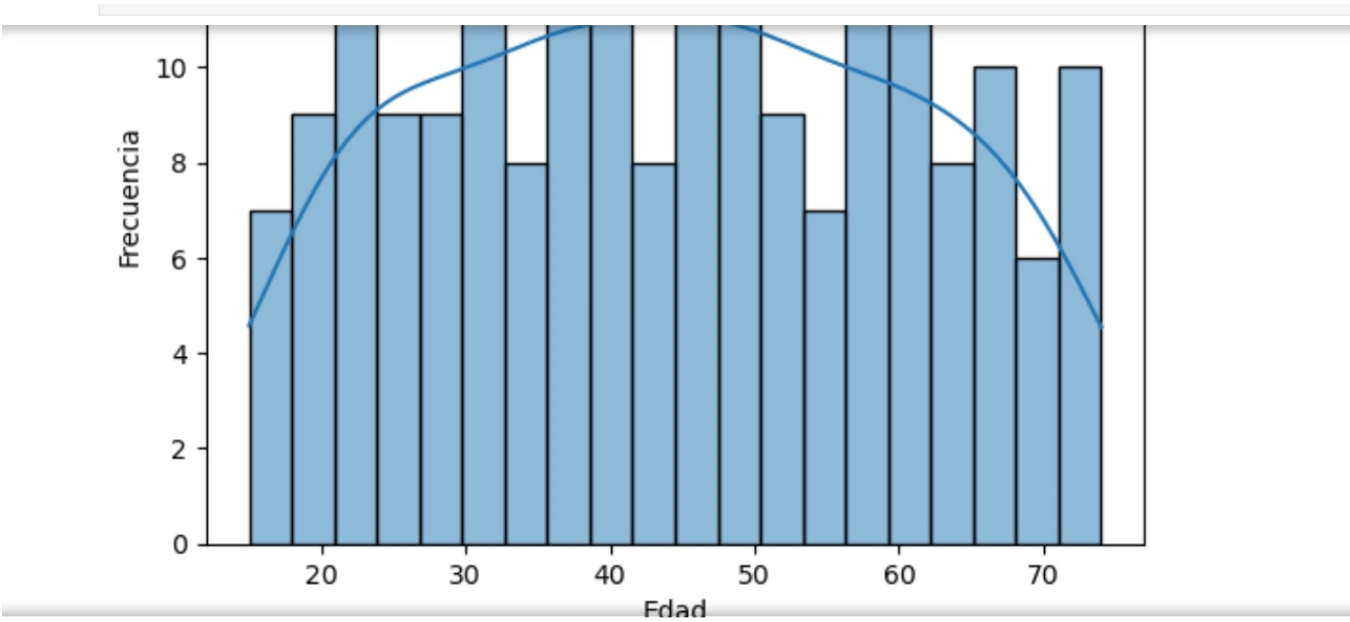

2. **Gráfico de Dispersión Na-K:**
   Nos muestra como de distribuyen las diferentes muestras y la coincidencia de cada una de llas con la otra, mostrando una gran dispersión, ya que no detectamos ningún área donde haya especial predominancia o agrupamiento de puntos.

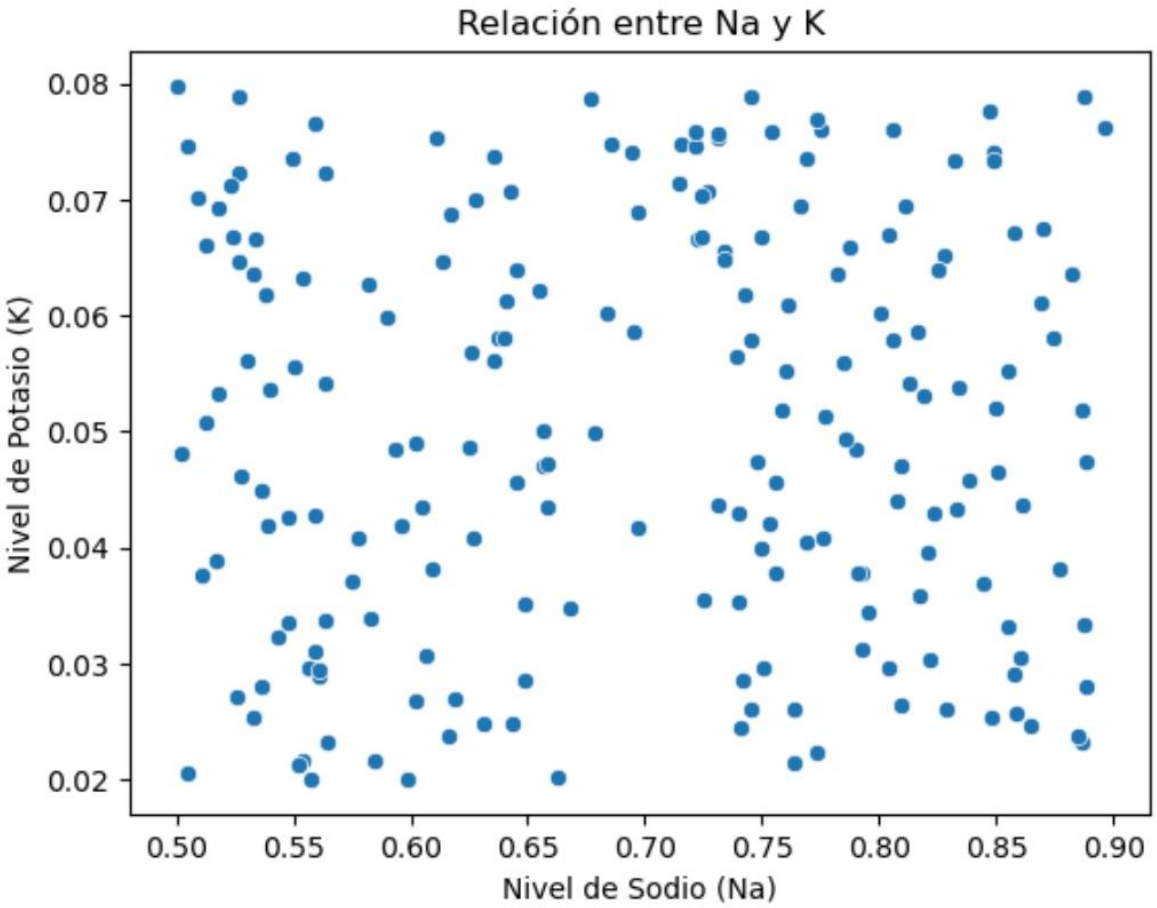

3. **Mapa de Calor Age-Na-K:**
   No hay índices de altas correlaciones positivas entre estas variables, por lo que podría indicar que es difícil que se dé excesiva correlación y posible sesgo en el modelo. Encontramos una leve correlación positiva entre las variables.

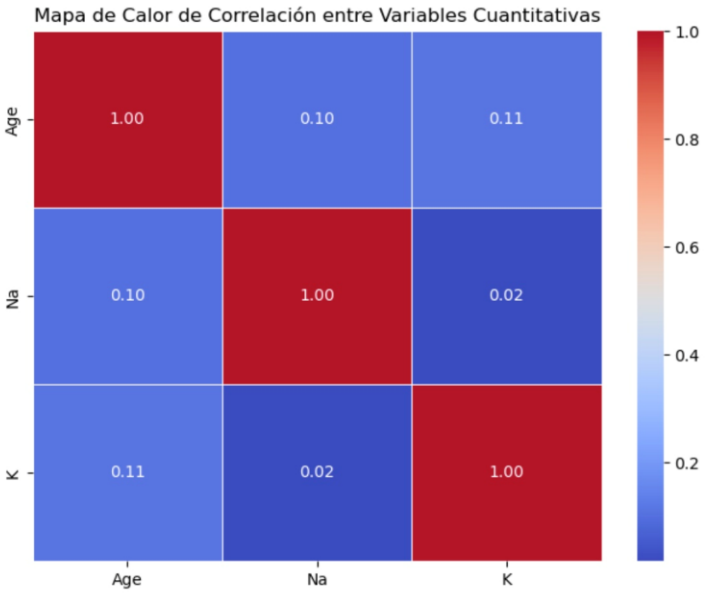

4. Evolución de Niveles de Sodio y Potasio por Edad:
   Donde destacamos la bajada que tiende sufrir el nivel de Na en sangre en la edad de los 30, siendo la de K cercana a los 70. Encontramos un punto donde ambas tienen un dato excesivamente bajo, sobre los 55 años. Ambas variables han sido estandarizadas antes de realizar el gráfico, ya que se evalúan en escalas diferentes y por ende afecta a su expresión.

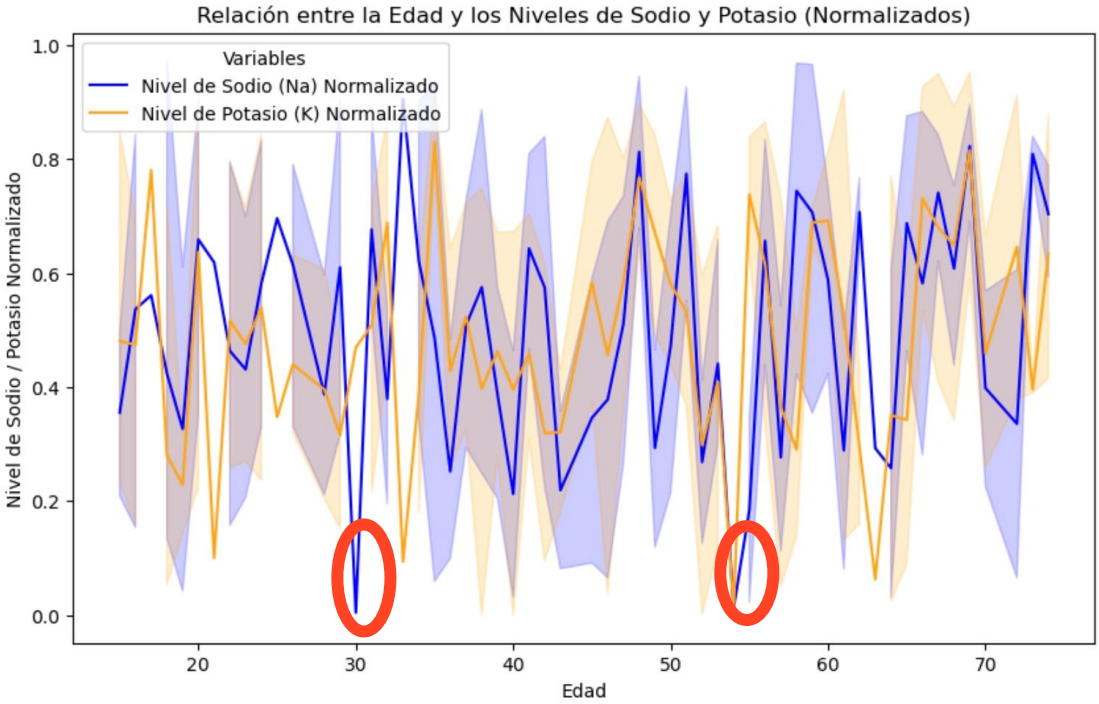

5. Pie Chart Drogas:
   Predominancia del uso de droga Y (45%), después le sigue la droga X (27%), droga A (11%) y ambas drogas B y C con un 8%. Para obtener conclusiones más específicas acerca de estos medicamentos necesitaríamos información más detallada, pero de manera hipotética podríamos formular que las drogas Y y X, son las más comunes y probablemente las más suaves, mientras que el resto podrían aumentar su dureza y por ello ser menormente usadas.

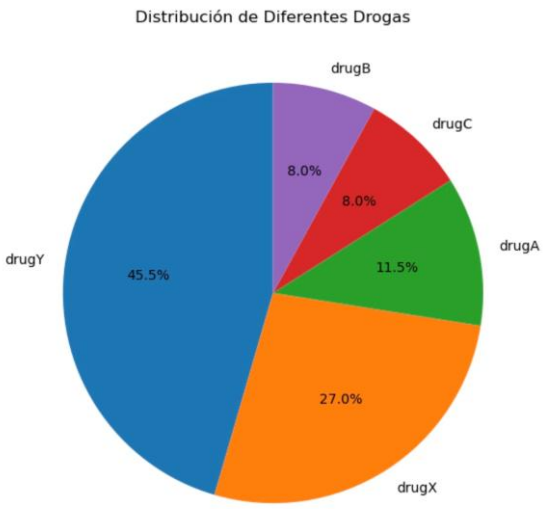

Recodificación y transformaciones necesarias

Previamente hemos llevado cabo la transformación de las variables Potasio(K) y Sodio(Na), las cuales inicialmente eran de tipo objeto(cadena de texto o string), las hemos transformado a float, con el objetivo de poder manipular y estudiar de manera cuantitativa su peso en la droga a emplear.
A la vez, hemos recodificado las variables categóricas a dummies, utilizando el método get_dummies. Estas variables son algunas como "Sex", "BP" o "Cholesterol", mientras que la variable "Drug", no ha sido cambiada en un principio, pero si más adelante, con el objetivo de facilitar su clasificación.
Como antes hemos mencionado, he normalizado las variables "Na" y "K", ya que ambas aparte de haber sido transformadas de object a float, se evalúan en escalas diferentes. La estandarización se ha hecho con el objetivo de evitar dominio de alguna variable sobre otra.

Implementación de modelos: KNN

Comenzamos con la elaboración del primero de los modelos, K vecinos más cercanos. Este modelo será probado con diferentes K, buscando acercarnos lo máximo posible a la K óptima, la cual determinaremos más adelante. Esta será evaluada con, métricas como Recall, F1-Score o Accuracy. Les presento los diferentes pasos llevados a cabo:

1. Importamos librerías necesarias (pandas, numpy, seaborn o KneighborsClassifier…)

2. Definimos conjuntos X e y, siendo X(Age, Sex_M, BP_LOW, BP_NORMAL, Na_normalized, K_normalized, Cholesterol_NORMAL) e y(Drug).Hemos de tener en cuenta que las variables, ya han sido recodificadas y estandarizadas.

3. Preprocesamos los datos, elaborando los conjuntos de entrenamiento y prueba para ambas variables, con un tamaño de entre del 70% y de prueba del 30%.

4. Entrenamos el modelo cuando **K=5** y lo evaluamos a través de la matriz de confusión.
   4.1De la cual podemos extraer que el modelo clasifica bien la Droga A, ya que 6 fueron correctamente clasificadas (verdaderos positivos)
   4.2 2 instancias fueron equívocamente clasificadas como Droga A, cuando realmente eran Droga B.
   4.3 1 instancia de la clase 4(Droga X) fue equívocamente clasificada como Droga B.

5. Entrenamos el modelo cuando **K=16** y lo evaluamos a través de la matriz de confusión.
   5.1 Encontramos un total de 6 instancias clasificadas correctamente como Droga A, (VP)
   5.2 Distinguimos 1 falso negativo al haber clasificado erróneamente la Droga A
   5.3 Los falsos positivos, son 3.
   5.4 Encontramos 42 casos en los que no se ha clasificado de manera correcta a Droga A

6. Entrenamos el modelo cuando **K=2** y lo evaluamos a través de la matriz de confusión
   6.1 encontramos un total de 6 Verdaderos positivos, buena clasificación de la droga A
   6.2 Sin embargo, disminuye el total de Falsos Negativos a 19, siendo estas las clasificaciones que no se han hecho de manera correcta a la Droga A.

Determinación de K Óptimo

Hemos implementado el código proporcionado en los apuntes para determinar el K óptimo, el cual será evaluado por las métricas y la matriz de confusión.

1. K óptimo = 17

2. Matriz de confusión: destacamos la buna clasificación que indica a través de los valores diagonales. Indicando que el modelo clasifica bien la mayoría de las instancias. Pocos errores graves, únicamente una instancia clasifica la droga A, como X. Y buen rendimiento en la clase predominante, con 24 predicciones correctas y 3 errores.

3. Comparación Métricas:
   3.1 Precisión: todas superan el 70%, menos Droga C, y Droga B, tiene precisión de 1, significa que siempre clasifica bien.
   3.2 Recall: todos se sitúan por encima del 80%, mientras que Droga C, tiene un 60%, indicando su limitada capacidad para identificar instancias verdaderas.
   3.3 F1-Score: todos suelen tener por encima de 70%, sin embargo, a la droga C le penaliza el Recall medio.
   3.4 Support: destacamos la droga Y, como la clase dominante en el conjunto de datos.

4. Accuracy: el modelo clasifica correctamente el 83% de las veces en los conjuntos de prueba. Indica robustez en el modelo, pero tiene margen de mejora todavía.

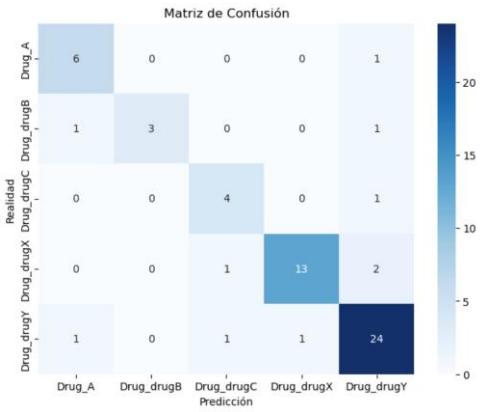

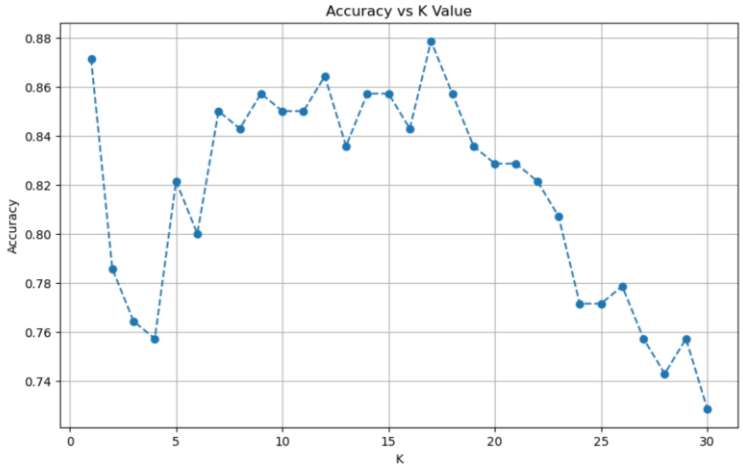

Implementación de modelos: Árbol de Decisión

Hemos desarrollado un modelo basado en los árboles de clasificación. El proceso de desarrollo es semejante al del modelo de KNN, sin embargo, hay algunos matices a tener en cuenta. Comenzamos importando las librerías necesarias como son numpy, pandas o DecissionTreeClassifier. Continuamos con la definición de variables, ambos conjuntos tanto la X como la y. Crearemos y ajustaremos el modelo, teniendo en cuenta las predicciones. Una vez hayamos hecho el modelo lo evaluaremos con las mismas métricas anteriores.

1. **Precisión**: destacan la drugB y drugc, por su poca precisión en cuanto a la clasificación, ya que una ronda el 50% y la otra con un 43%, no tienen buena precisión.

2. **Recall:** la droga B, mantiene el 100% de aciertos, mientras que otras como la droga C, tiene un índice inferior a 50%, otras como droga A con 57%, disminuye en comparación al modelo anterior.

3. **F1-Score**: el máximo cifra en 79%, mientras que en el anterior todos a excepto de uno superaban esta cifra, siendo la droga c, la peor con un 43%.

4. **Support**: se mantiene la predominancia de la mima clase (Droga Y), al igual que en el modelo anterior.

5. **AUC-CURVA ROC:** 0.81, lo cual indica una alta capacidad para diferenciar entre clases, ya que refleja la relación entre Tasa de verdaderos positivos y tasa de Falsos positivos.

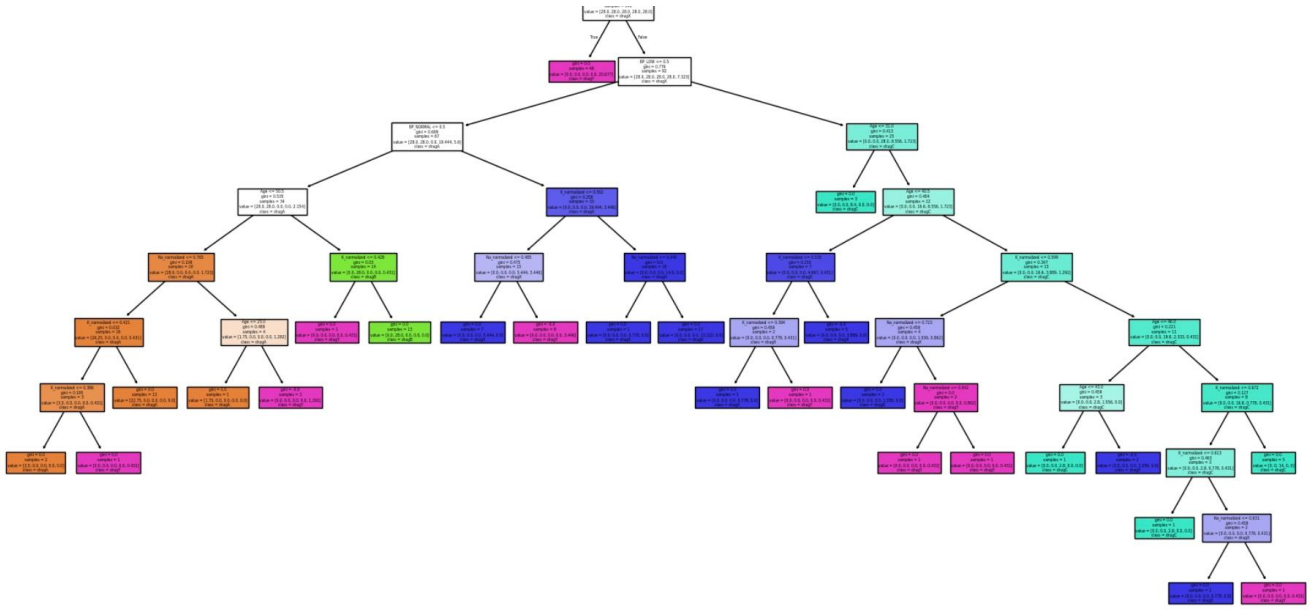

```
AUC-ROC Score: 0.8152314808573935
```

Comparación modelos.

Concluimos que el modelo de KNN es más efectivo que el de árboles de decisión por las siguientes razones:

- En el caso de la precisión, el primer modelo supera en porcentaje al segundo de manera media, situándose prácticamente todos los del primero por encima del 80%, mientras que en el segundo modelo rondan el 50%.
- En base a Recall: la clase (Droga B) mantiene constante su 100% de efectividad en cuanto a la clasificación, mientras que el primer modelo presenta un mejor Recall que el segundo.

- F1-Score: el primer modelo presenta en líneas generales, una puntuación por encima del 80%, mientras que el segundo únicamente obtiene un porcentaje idéntico una clase, haciendo de lo habitual en el primer modelo, la excepción en el segundo.

- Support, no hay diferencias, ya que la misma clase domina la base de datos, y no cambia de un modelo a otro.

Implementación de VALIDACIÓN CRUZADA

Implementamos la validación cruzada, con métodos de Kfold, Stratified Validation, Leave One Out Validation y KFold Cross Validation. He implementado el código proporcionado en los apuntes y la evaluación es la siguiente.

Tras evaluar el gráfico podemos concluir que la validación clásica, es aquella con mayor posibilidad de error cuando la k es mayor, pero a medida que disminuye la k, esta se consolida como la más fiable, seguida por el Stratified Kfold, presentando el mayor margen una vez ha disminuido la k. Y otras como Repeated Kfold o Kfold mantienen un desarrollo constante y prácticamente semejante a lo largo de la variación de las k.

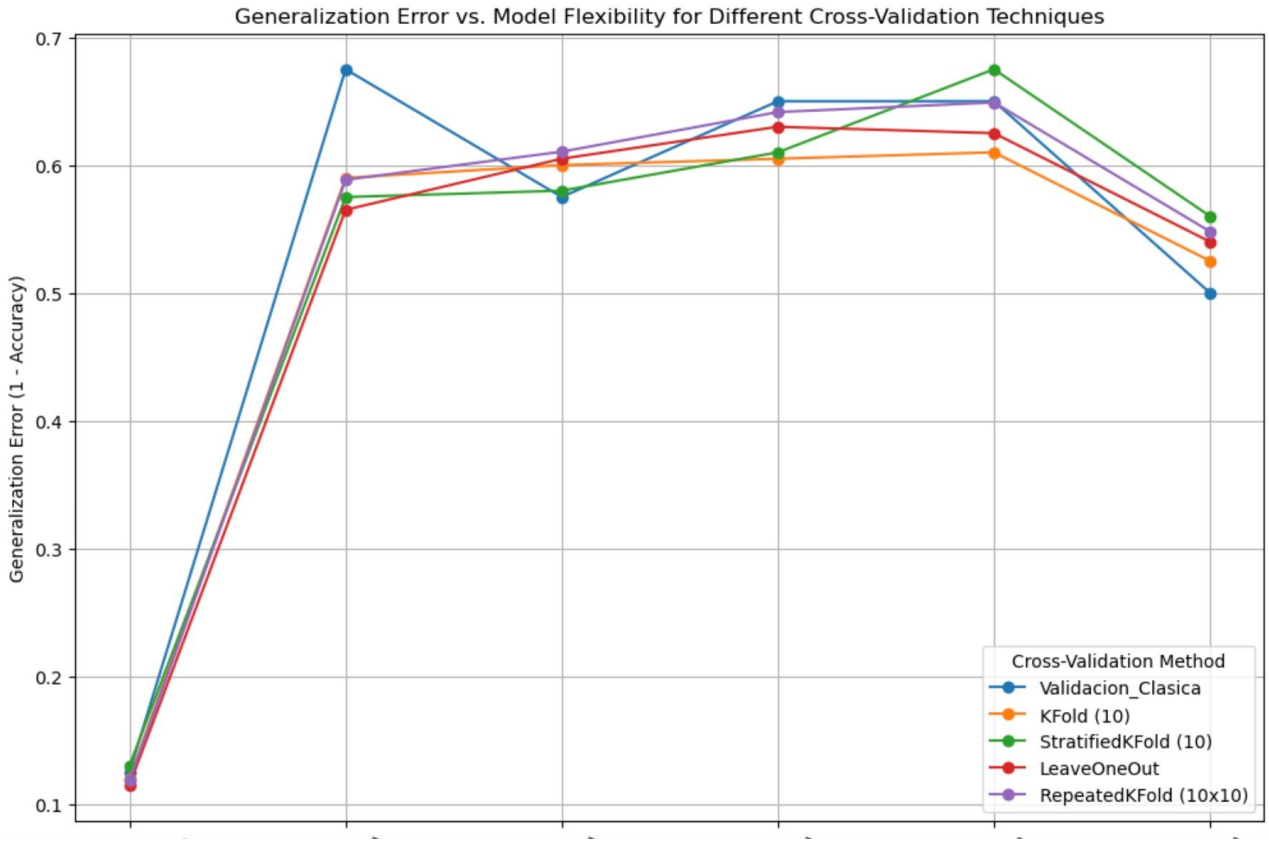

TRIBUNAL SUPREMO

Para reemplazar el texto de marcador de posición de esta página, basta con que lo seleccione todo y empiece a escribir. Pero no empiece todavía.

En primer lugar, échele un vistazo a algunas sugerencias que le ayudarán a agilizar el proceso de dar formato al informe. Le sorprenderá lo fácil que es.

- ¿Necesita un título? En la galería de estilos de la pestaña Inicio, haga clic en el estilo de título que quiera.
- Puede ver que en la galería también hay otros estilos. Por ejemplo, para una cita, una lista numerada o una lista con viñetas como esta.
- Para obtener los mejores resultados al seleccionar el texto que quiere copiar o editar, no incluya ningún espacio a la izquierda o la derecha de los caracteres de la selección.

TRIBUNALES DE APELACIÓN

Tal vez la fotografía de la portada le guste tanto como a nosotros, pero si no es la más indicada para el informe, puede reemplazarla fácilmente por una suya.
Basta con que elimine la imagen del marcador de posición. Después, en la pestaña Insertar, haga clic en Imagen para seleccionar una de sus archivos.